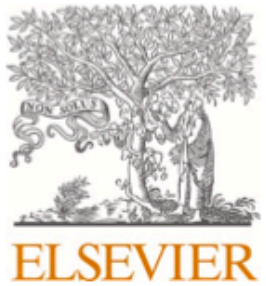
NeuroImage 311 (2025) 121185



Contents lists available at ScienceDirect

NeuroImage

journal homepage: www.elsevier.com/locate/ynimg





Identification of functional dynamic brain states based on graph attention networks

Inyoung Baek [a,1], Jong Young Namgung [b,1], Yeongjun Park [b,c], Seongil Jo [a,d,*], Bo-yong Park [b,e,**]

[a] Department of Statistics and Data Science, Inha University, Incheon, Republic of Korea
[b] Department of Brain and Cognitive Engineering, Korea University, Seoul, Republic of Korea
[c] BK21 Four Institute of Precision Public Health, Republic of Korea
[d] Department of Statistics, Inha University, Incheon, Republic of Korea
[e] Center for Neuroscience Imaging Research, Institute for Basic Science, Suwon, Republic of Korea

Theory

Preprocessing

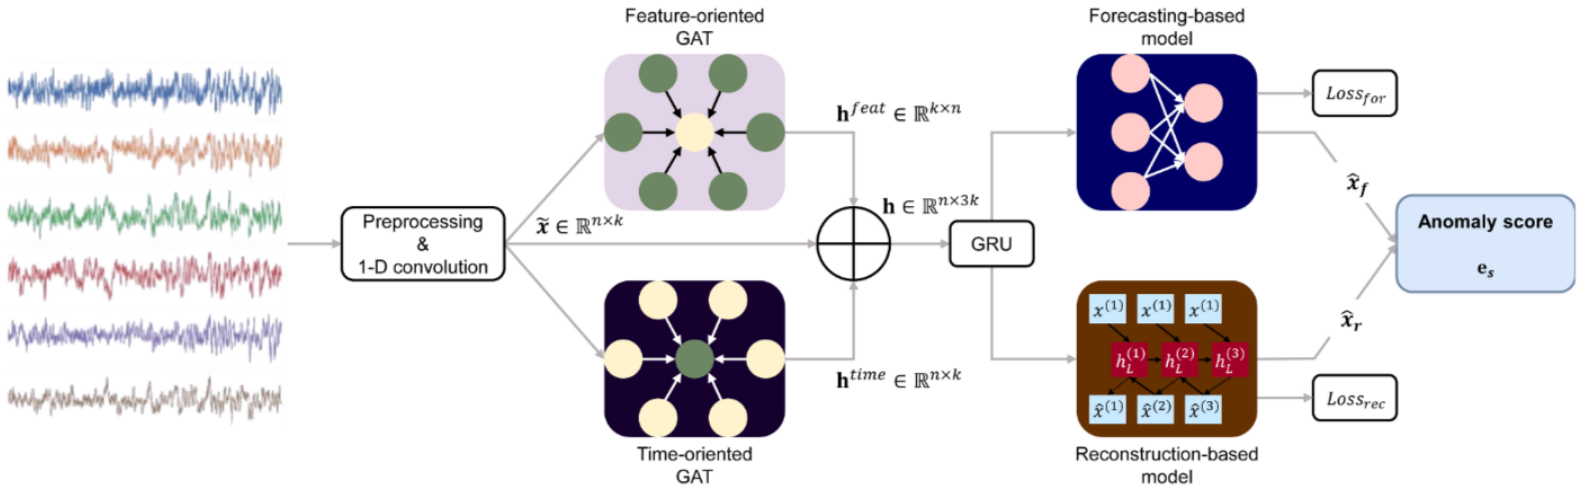
- multi-variate analysis of four-dimensional (4D) fMRI data
  - atlas parcellating ROIs(R개)
  - Min-max normalization(train, val)
  - spectral residual (SR) 기법으로 학습 중 특이 timestamp를 일부 정리
- 1D convolution 층 → 병렬 GAT 두 개(Feature-oriented, Time-oriented) → 출력들을 concat → GRU로 시퀀스 표현 학습
- Feature-oriented GAT: 노드 = 각 univariate time series(k개), 노드 간 관계(=features 간 상관)를 학습
- Time-oriented GAT: 노드 = 타임스텝(슬라이딩 윈도우 내 n개 타임스텝), 타임포인트 간 의존성 학습

Dataset

- SlHuman Connectome Project (HCP) S1200, 1010명(young adults)
- Structural MRI

Theory

Architecture



rs-fMRI → parcellation → X ∈ ℝ^{T × K}

T: time points (1200)

K: ROI 수 (200 / 300 / 360)

- Conv1D: local temporal pattern 추출
  - Input: (B, 64, K)
  - Output: X̃ ∈ (B, 64, K)
  - K : features 수 (ROI수)
  - 64 : 입력시계열 길이

- Feature-oriented GAT
  - Input : K nodes, each with 64-dim sequence
  - Output : h_feat ∈ ℝ^{K × 64(시퀀스길이=n}
  - Node = univariate time series of ROI
  - Edge = ROI 간 functional dependancy

- Time-oriented GAT
  - Input : 64 nodes(window 길이) 각 time t의 feature: x_t ∈ ℝ^{K}
  - Output : h_time ∈ ℝ^{64 × K}
  - Node : sliding window 내의 각 timestamp
  - Edge : timestep 간 dependancy

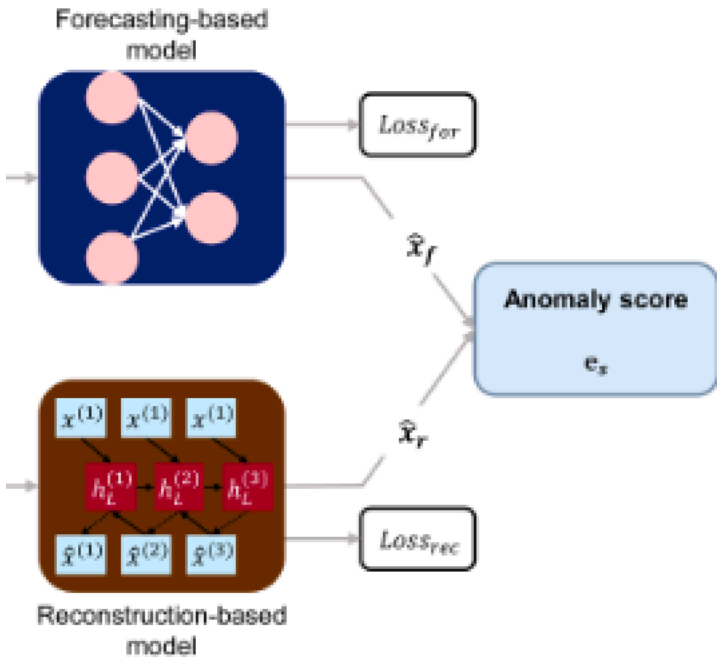
- Feature fusion
- Concat
  - Conv1D output: (64 × K)
  - Feature-GAT output: (64 × K) ← transpose
  - Time-GAT output: (64 × K)
    - → (64 × 3K)

- GRU :long-range dependency summary
  - Input: (64, 3K)
  - Hidden: h ∈ ℝ^{d1} (d1=128)

- Dual Head = Joint optimization
  - Forecast loss
  - Reconstruction loss

Theory

Architecture



- Dual Head = Joint optimization
  - Forecast loss
  - Reconstruction loss

$$Total\ Loss = Loss_{for} + Loss_{rec}$$

$$Loss_{for} = \frac{1}{n}\sum_{j=1}^{n}\sum_{i=1}^{k}\sqrt{(x_{ij} - f(h_{ij}))^2} = \frac{1}{n}\sum_{j=1}^{n}\sum_{i=1}^{k}\sqrt{\left(x_{ij} - \hat{x}_{ij}^{f}\right)^2},$$

$$Loss_{rec} = \frac{1}{n}\sum_{j=1}^{n}\sum_{i=1}^{k}\sqrt{(x_{ij} - g(h_{ij}))^2} = \frac{1}{n}\sum_{j=1}^{n}\sum_{i=1}^{k}\sqrt{\left(x_{ij} - \hat{x}_{ij}^{r}\right)^2},$$

n: 샘플(윈도우) 수
k: 변수(노드) 수

Forecasting: 단기 변화에 민감하게 학습함. 갑작스런 변화가 있으면 다음 스텝 예측 오차가 커짐.
Reconstruction: 윈도우 전체 패턴을 캡처. 정상 패턴과 다른 시퀀스는 재구성 오차가 커짐.

- Anomaly score

$$\mathbf{e}_s = \frac{1}{k}\sum_{i=1}^{k} s_i = \frac{1}{k}\sum_{i=1}^{k}\left(\gamma_1\sqrt{\left(x_{ij} - \hat{x}_{ij}^{f}\right)^2} + \gamma_2\sqrt{\left(x_{ij} - \hat{x}_{ij}^{r}\right)^2}\right) \in \mathbb{R}^n,$$

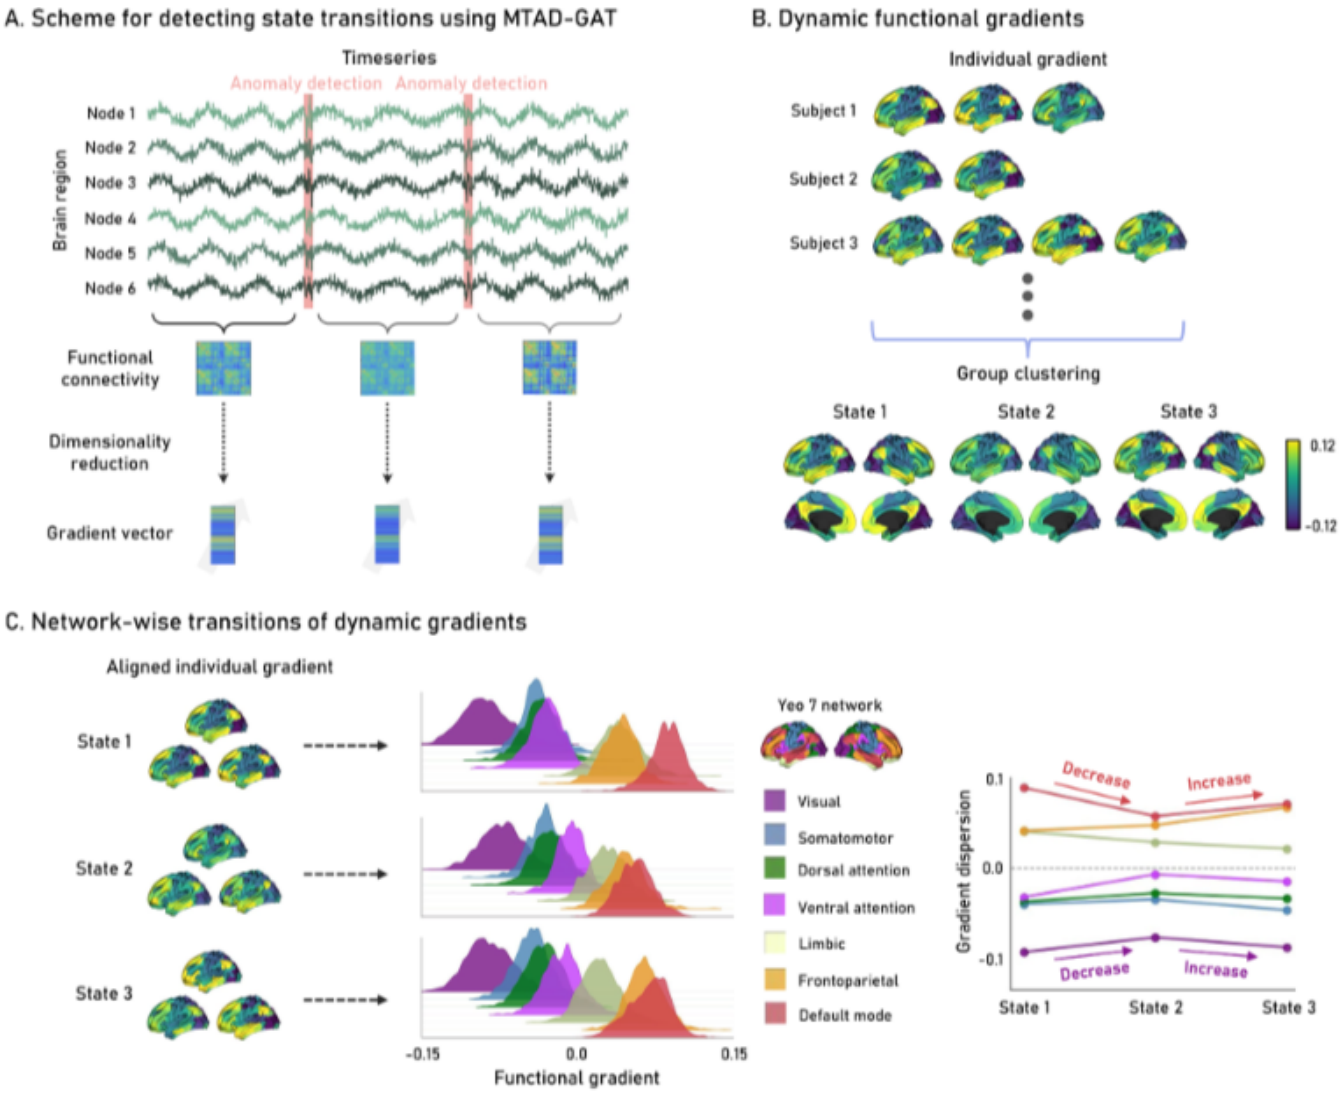
i	feature index (ROI index)
j	time index (window 안의 특정 시점)
k	전체 feature 수 (= ROI 수)
n	전체 time length

x_{ij}	ROI i의 time j에서의 실제 값
$\hat{x}_{ij}^{f}$	forecasting head가 예측한 값
$\hat{x}_{ij}^{r}$	reconstruction head가 복원한 값

Result

Dynamic brain state identification

- Functional gradient
  - MTAD-GAT로 검출된 변화점(change points)=시간축을 분할
  - sub-time series의 functional connectivity(FC) 행렬> 저차원 그래디언트(gradient)를 얻음
- group-level brain staes
  - 개별 gradient 모음 (총 n행 × p열)
  - 이 전체 gradient 행렬에 GMM Clustering 적용
  - group-level brain states 도출
- 결론
  - S1, S3: gradient 분산(혹은 분산도)이 커서 네트워크가 더 분리(segregated)된 패턴.
  - S2: 분산이 작고 여러 영역이 더 골고루 섞여 통합(integrated)된 패턴.
  - 세 상태는 뇌가 시간에 따라 '분리된 기능 중심 모드(특정 감각/운동 루틴 등)'와 '통합된 멀티네트워크 모드(정보 통합·고차 인지)' 사이를 오간다는 관점과 일치.

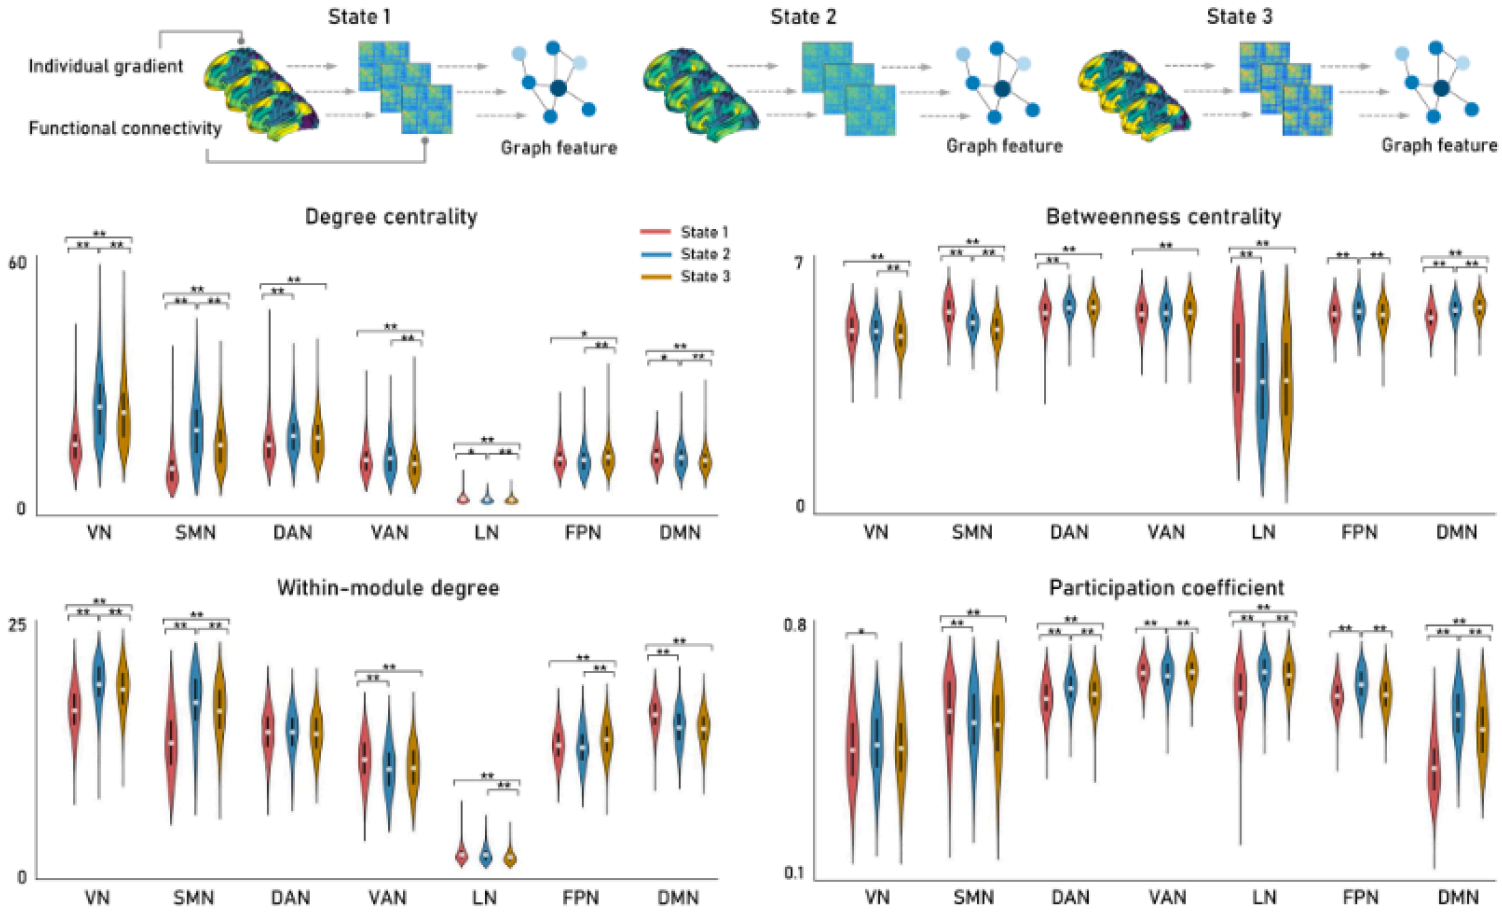


Result

Topological characteristics of dynamic brain state

- 목적
  - 각 brain state에서의 네트워크 구조를 정량화하기 위해 그래프 이론적 지표들을 계산한 방법과 통계·강건성 검증 절차

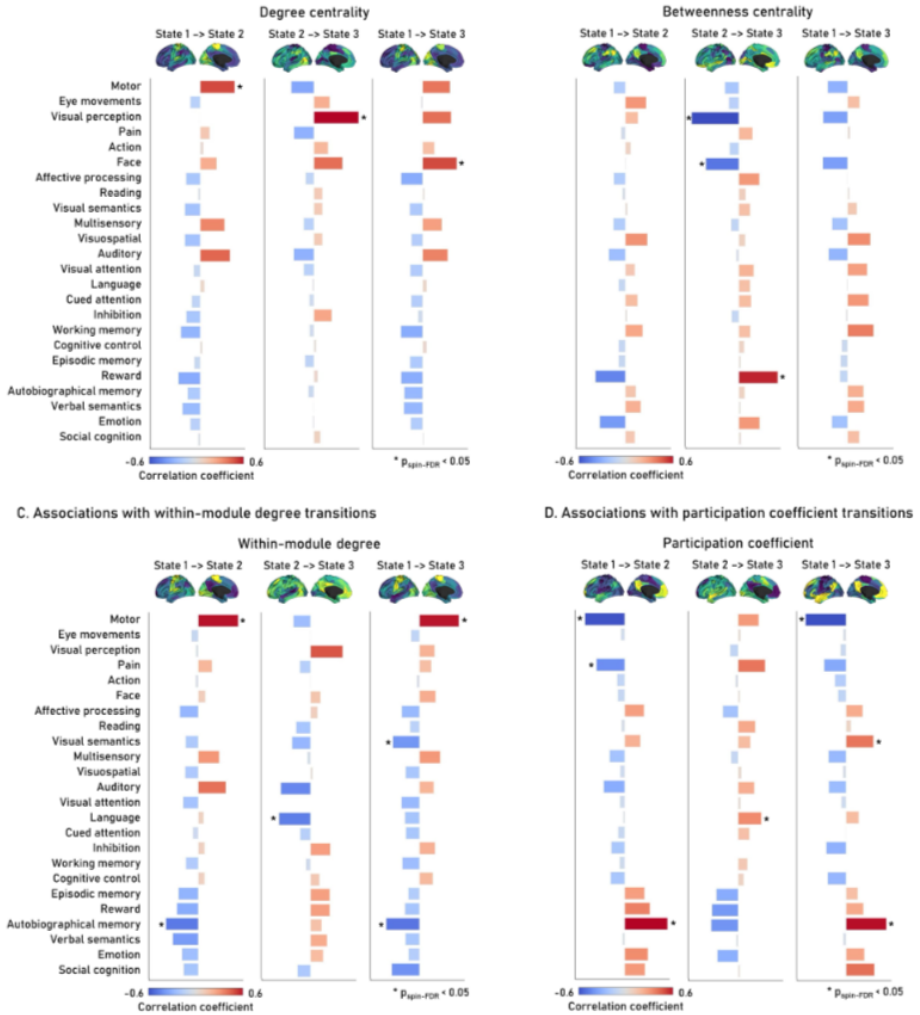
- 결론
  - 세 가지 brain states (State 1 = 빨강, State 2 = 파랑, State 3 = 노랑)에 대해 7개 네트워크(VN, SMN, DAN, VAN, LN, FPN, DMN)마다 네 가지 그래프 지표 (Degree centrality, Betweenness centrality, Within-module degree, Participation coefficient)의 분포를 violin plot으로



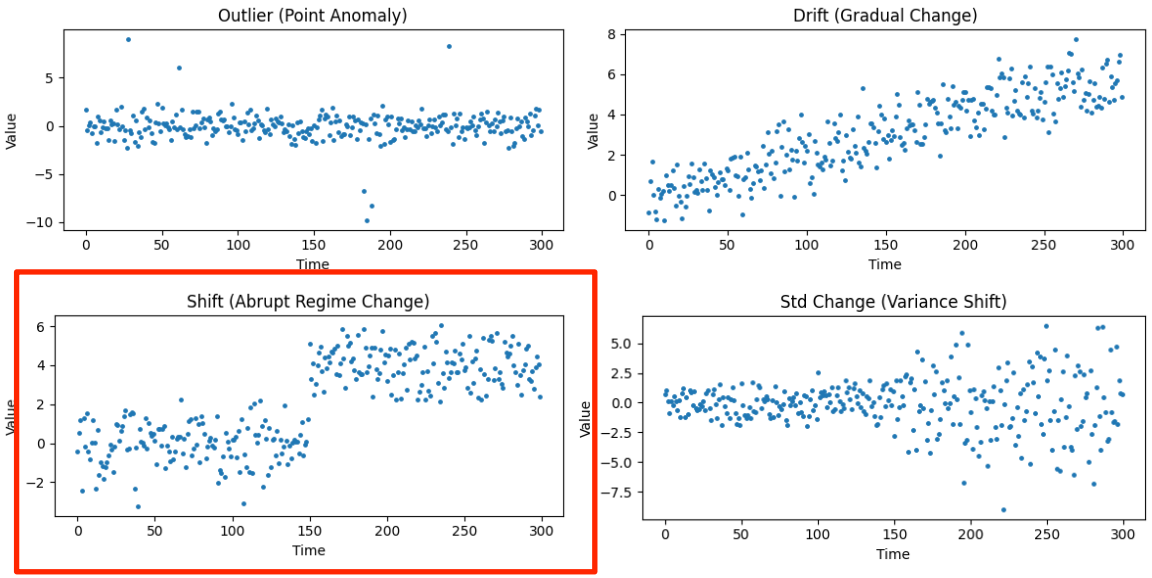
Result

Associations of state transitions with task activation maps

- 목적
  - 서로 다른 brain state 간 전이(transition)에서 관찰된 네트워크 변화(graph feature 차이)가 어떤 인지 기능과 관련되는지 확인
  - 비교 대상: 그래프 특성 차이
- 결론
  - 전이(예: State1 → State2)에서의 "뇌 영역별 그래프 지표의 변화값"과 각 Neurosynth 인지맵(영역별 활성값) 간의 선형 상관관계를 계산
  - 뇌 상태 전이 할때 지표 변화값과 기존에 보고된 특정활동에서 활성화되는 영역이 겹치는 지 확인



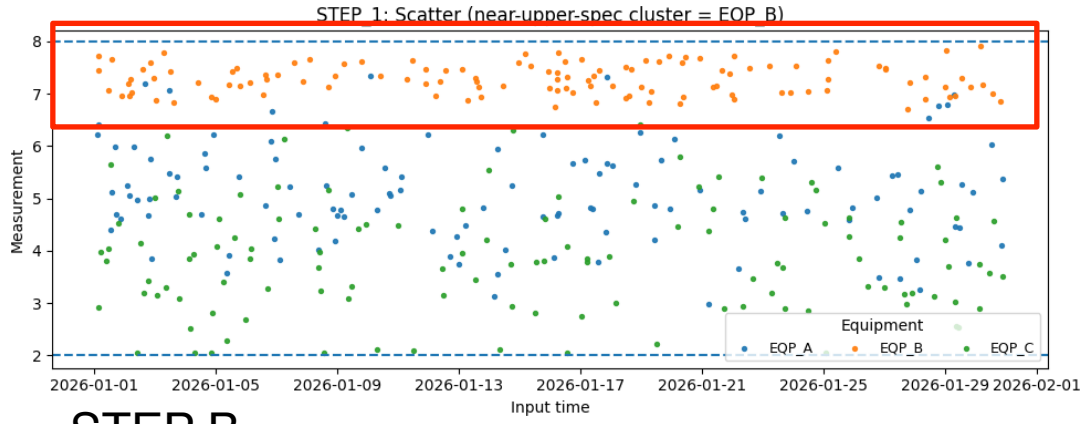
Anomaly detection



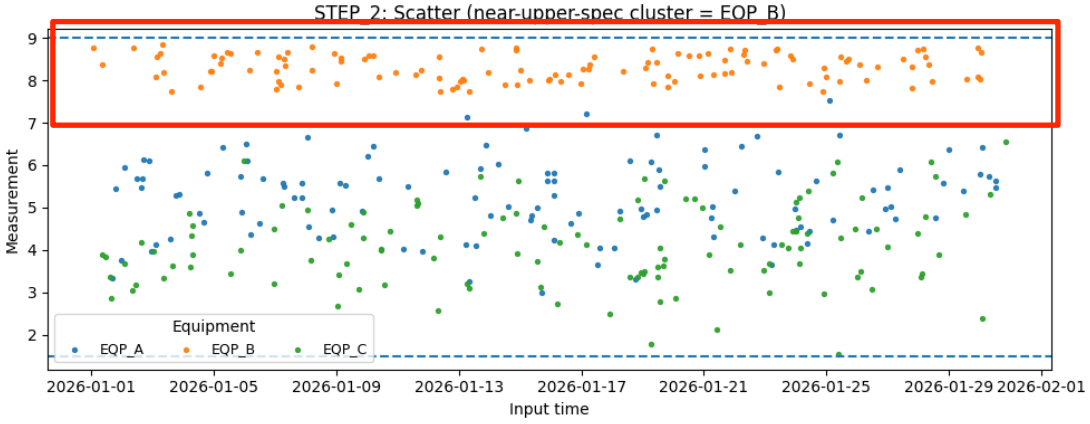
- EQP A= subject A(사람)
- STEP = ROI(parcel)

- 반도체
  - 같은 EQP 진행한 point 라고 해도 본질적으로 point 들이 independent(다른 wafer)
  - EQP 별 timestep이 일정하지 않음

STEP A



STEP B



Thank you